

Ciência de Dados


Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza



Aprendizado de Máquina

Aprendizado de Máquina (*Machine learning*) é uma área da Inteligência Artificial (IA) e da ciência da computação que se concentra no uso de dados e algoritmos para imitar a maneira como os humanos aprendem, melhorando gradualmente sua precisão.



Aprendizado de Máquina

“Campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados”

Arthur Samuel (1959)



Aprendizado de Máquina

O **Aprendizado de Máquina** é um campo de pesquisa dedicado a entender e construir algoritmos que 'aprendem', ou seja, que aproveitam dados para melhorar o desempenho em algum conjunto de tarefas.

Tipos de Aprendizado:


Aprendizado Supervisionado

- Regressão
- Classificação

Aprendizado Não Supervisionado

- Agrupamento
- Detecção de Anomalias


Aprendizado de Máquina



Tipos de Aprendizado



Supervisionado:

- Dado rotulado



Não-supervisionado:

- Dado não rotulado




Aprendizado Supervisionado

Os dados são rotulados, isto é, a **“resposta certa” é dada**


Regressão

Prever uma saída contínua (preço)



Classificação

Prever uma saída discreta (e-mail / Spam)



Aprendizado Supervisionado

A função mapeia uma entrada para uma saída com base em pares de entrada-saída de exemplo.



Exemplos	Features				Labels
	SqFt	Bedrooms	Bathrooms	Neighborhood	Price
	1790	2	2	East	114300
	2030	4	2	West	114200
	1740	3	2	East	114800
	1980	3	2	West	94700
	2130	3	3	East	119800

Novos Exemplos			
SqFt	Bedrooms	Bathrooms	Neighborhood
2030	3	3	East
1780	3	2	North
1830	3	3	West
2160	4	2	West
2110	4	2	East

Aprendizado Não supervisionado


Agrupamento (clustering)

Agrupa o dado não rotulado de acordo com as suas características (features)



Detecção de Anomalias

Detecta padrões incomuns em dados não rotulados



Aprendizado Semi-supervisionado


Aprendizado Não-supervisionado + Aprendizado Supervisionado

Características:

- Rotulação do dado geralmente demanda tempo e dinheiro;
- Frequentemente os dados terão muitas instâncias não rotuladas.

Passo 1 - Algoritmo de agrupamento para “clusterizar” as instâncias semelhantes e rotular o dado

Passo 2 - Aplicação do aprendizado supervisionado no dado rotulado




Aprendizado Supervisionado

Regressão Linear

Regressão Linear

Tamanhos e preços de casas



Hipótese da regressão linear

**Modelo de Aprendizado
Supervisionado**

A “resposta certa” é dada para
cada exemplo dos dados.

Modelo de **Regressão** prevê
números

Regressão Linear

Tamanhos e preços de casas





Tabela de dados

size in feet ²	price in \$1000's
2104	400
1416	232
1534	315
852	178
...	...
3210	870


x "input" variável de entrada característica (*feature*)

y "output" variável alvo "target"

Regressão Linear



Como representar f ?



Regressão Linear

Preço dos imóveis

Conjunto de treinamento

SqFt	Bedrooms	Bathrooms	Neighborhood	Price
1790	2	2	East	114300
2030	4	2	West	114200
1740	3	2	East	114800
1980	3	2	West	94700
2130	3	3	East	119800

Conjunto de teste

SqFt	Bedrooms	Bathrooms	Neighborhood
2030	3	3	East
1780	3	2	North
1830	3	3	West
2160	4	2	West
2110	4	2	East

Ideia: Encontrar a hipótese que explica bem os dados.

Regressão Linear

features	target
size in feet ² (x)	price \$1000's (y)
2104	460
1416	232
1534	315
852	178
...	...

Modelo

$$f_{w,b}(x) = wx + b$$


w, b

Parâmetros
Coeficientes
Pesos


Função de custo

$$f_{w,b}(x) = wx + b$$


$$f(x)$$



$$w = 0$$
$$b = 1,5$$




$$w = 0,5$$
$$b = 0$$



$$w = 0,5$$
$$b = 1$$

Função de custo

Mede a **distância** do rótulo para a hipótese



Função de custo

Modelo: $f_{w,b}(x) = wx + b$

Parâmetros: w, b

Função de Custo:

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})^2$$

Objetivo: $\underset{w,b}{\text{minimize}} J(w, b)$

Simplificação



$$f_w(x) = wx$$

w

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (f_w(x^{(i)}) - y^{(i)})^2$$

$\underset{w}{\text{minimize}} J(w)$

Função de custo



Fim