

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza



Relembrando a Função de custo

Modelo:

$$f_{w,b}(x) = wx + b$$

Parâmetros:

$$w, b$$

Função de Custo:

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})^2$$

Objetivo:

$$\underset{w, b}{\text{minimize}} J(w, b)$$

Simplificação



$$f_w(x) = wx$$

$$w$$

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (f_w(x^{(i)}) - y^{(i)})^2$$

$$\underset{w}{\text{minimize}} J(w)$$

Relembrando a Função de custo




Gradiente Descendente

A **Descida de Gradiente** ou (gradiente descendente) é um algoritmo de otimização iterativa de primeira ordem para encontrar um **mínimo local de uma função diferenciável**.

A **intuição** é dar passos repetidos na direção oposta do gradiente da função no ponto atual, pois esta é a **direção de descida mais acentuada**.

A descida do gradiente é baseada na observação de que se a função multivariável $F(\mathbf{x})$ é definida e diferenciável em uma vizinhança de um ponto $\mathbf{a}$, então $F(\mathbf{x})$ diminui mais rapidamente se formos de $\mathbf{a}$ na direção do gradiente negativo de F em $\mathbf{a}$, $-\nabla F(\mathbf{a})$.

Gradiente Descendente



Não é o erro ao quadrado
e
não é a regressão linear

Mínimos locais

Implementação

Repetir até convergir

$$w = w - \alpha \frac{\partial}{\partial w} J(w, b)$$

$$b = b - \alpha \frac{\partial}{\partial b} J(w, b)$$

Taxa de aprendizado
("tamanho do passo")

$$tmp_w = w - \alpha \frac{\partial}{\partial w} J(w, b)$$

$$tmp_b = b - \alpha \frac{\partial}{\partial b} J(w, b)$$




$$w = tmp_w$$



$$b = tmp_b$$

Intuição

$$J(w)$$
$$w = w - \alpha \frac{\partial}{\partial w} J(w)$$
$$\min_w J(w)$$



$$w = w - \alpha \frac{\partial}{\partial w} J(w)$$
$$> 0$$
$$w = w - \alpha \cdot (\text{positive number})$$



$$w = w - \alpha \frac{\partial}{\partial w} J(w)$$
$$< 0$$
$$w = w - \alpha \cdot (\text{negative number})$$

Cr terios de Parada: Como saber quando parar?


Na pr tica, o algoritmo n o sabe sozinho quando chegou ao m nimo exato. Precisamos definir uma **condi  o de parada no c digo**.

- **Abordagem 1: N mero fixo de itera  es ( pocas)**
 - Definimos previamente um limite m ximo de passos (ex: 1000 itera  es).
 - *Risco*: Pode parar antes de achar o m nimo ou continuar calculando desnecessariamente ap s j  ter chegado ao fundo da “tigela”.
- **Abordagem 2: Toler ncia ao Erro (ϵ)**
 - Monitoramos a mudan a na Fun  o de Custo a cada passo. Se a diferen a entre o custo atual e o anterior for min scula, assumimos que o modelo convergiu.
 - Condi  o: Se $J_{\text{atual}} - J_{\text{anterior}} \leq \epsilon$ (onde ϵ   um valor pequeno como 0.001), o la o   interrompido.


Cr terios de Parada e Taxa de Aprendizizado

$$w = w - \alpha \frac{\partial}{\partial w} J(w)$$


Alta





Muito alta





Muito pequena





Adequada



Mínimos



Exemplos de Otimizadores



O Estado da Arte: Otimizador ADAM

Os otimizadores do slide anterior resolvem problemas específicos (ex: Momentum ajuda a sair de mínimos locais ganhando “embalo”).

O que é o Adam? (*Adaptive Moment Estimation*)

- Atualmente, é o otimizador padrão mais recomendado em Ciência de Dados e Deep Learning (TensorFlow, PyTorch).

Por que usá-lo?

- Ele une o melhor de dois mundos: utiliza o conceito de Momentum (suavizando a direção da descida) aliado à taxa de aprendizado adaptativa do RMSprop (ajustando passos maiores para variáveis infrequentes e passos menores para variáveis frequentes).
- Converte de forma incrivelmente rápida e exige menos calibração manual do hiperparâmetro α .

Gradiente Descendente para Regressão Linear

Modelo de Regressão Linear

$$f_{w,b}(x) = wx + b$$

Função de Custo:

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})^2$$

Algoritmo de Descida de Gradiente

Repetir até convergir {

$$w = w - \alpha \frac{\partial}{\partial w} J(w, b)$$



$$\frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)}) x^{(i)}$$

$$b = b - \alpha \frac{\partial}{\partial b} J(w, b)$$



$$\frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})$$

}

De onde vem o “x” na fórmula? (Regra da Cadeia)

- O objetivo é derivar a Função de Custo $J(w, b)$ em relação ao peso w : $\frac{\partial}{\partial w} J(w, b)$
- A Função de Custo original é:
$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})^2$$
- Pela regra da cadeia do Cálculo, a derivada de uma função ao quadrado “tomba” o expoente 2 multiplicando (cancelando com o 2 do denominador) e multiplica pela derivada do que está dentro do parênteses.
- Derivando o interior $(wx^{(i)} + b - y^{(i)})$ em relação a w , o b e o $y^{(i)}$ viram zero (são constantes), e a derivada de $w x^{(i)}$ é apenas o próprio $x^{(i)}$.
- **Resultado Final:** É por isso que o erro da previsão é multiplicado pela própria entrada $x^{(i)}$ para atualizar o peso w !

Gradiente Descendente para Regressão Linear

Repetir até convergir {

$$w = w - \alpha \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)}) x^{(i)}$$


$$b = b - \alpha \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})$$

}

Formato de “tigela” (bowl shape)


Função convexa

Custo do erro quadrático




Único mínimo global


Execução




Execução




Execução




Execução




Execução




Execução




Execução



Execução



Execução



Escalonamento de Variáveis (Feature Scaling)

O que acontece se tivermos regressão múltipla com variáveis em escalas muito diferentes? Exemplo:

x_1 = Número de Quartos [1 a 5]


vs.

x_2 = Preço do Imóvel [100.000 a 500.000]


- As curvas de nível da função de custo J perdem o formato de “tigela circular” e se tornam elipses extremamente esticadas e achatadas.
- Numa elipse esticada, o Gradiente Descendente sofre para encontrar a direção central, oscilando de um lado para o outro infinitamente.
- **A Solução:** Padronizar as variáveis (ex: usar Z-Score / Standardization) para que todas fiquem na mesma escala. O contorno volta a ser circular e o gradiente desce em linha reta e rápida.

Escalonamento de Variáveis (Feature Scaling)

**Sem Feature Scaling
(Superfície de "Tigela" Alongada)**




**Com Feature Scaling
(Superfície de "Tigela" Simétrica)**




Tipos de Gradiente Descendente


Batch Gradient Descent



Mini-Batch Gradient Descent



Stochastic Gradient Descent



Fim