

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza





Unifor

Principais desafios em Aprendizado de Máquina

- Quantidade insuficiente de dados de treinamento
- Dados de treinamento não representativos
- Dados de baixa qualidade
- Características irrelevantes
- Sobreajuste dos dados de treinamento
- Subajuste dos dados de treinamento

Algoritmos ruins e/ou dados ruins

Quantidade insuficiente de dados de treinamento



Problemas simples x Problemas complicados

Quantidade insuficiente de dados de treinamento

Scaling to Very Very Large Corpora for Natural Language Disambiguation

Michele Banko and Eric Brill

Microsoft Research

1 Microsoft Way

Redmond, WA 98052 USA

{mbanko, brill}@microsoft.com


Abstract

The amount of readily available on-line text has reached hundreds of billions of words and continues to grow. Yet for most core natural language tasks, algorithms continue to be optimized, tested and compared after training on corpora consisting of only one million words or less. In this paper, we evaluate the performance of different learning methods on a prototypical natural language disambiguation task

standardization of data sets used within the field, as well as the potentially large cost of annotating data for those learning methods that rely on labeled text.

The empirical NLP community has put substantial effort into evaluating performance of a large number of machine learning methods over fixed, and relatively small, data sets. Yet since we now have access to significantly more data, one has to wonder what conclusions that have been drawn on small data sets may carry over when these learning methods are trained using much larger corpora.

In this paper, we present a study of the



Dados x Algoritmos

Quantidade insuficiente de dados de treinamento



EXPERT OPINION

Contact Editor: **Brian Brannon**, bbrannon@computer.org

The Unreasonable Effectiveness of Data

Alon Halevy, Peter Norvig, and Fernando Pereira, *Google*

Eugene Wigner's article "The Unreasonable Effectiveness of Mathematics in the Natural Sciences"¹ examines why so much of physics can be neatly explained with simple mathematical formulas

such as $f = ma$ or $e = mc^2$. Meanwhile, sciences that involve human beings rather than elementary particles have proven more resistant to elegant math-


behavior. So, this corpus could serve as the basis of a complete model for certain tasks—if only we knew how to extract the model from the data.

Learning from Text at Web Scale

The biggest successes in natural-language-related machine learning have been statistical speech recognition and statistical machine translation. The reason for these successes is not that these tasks are

Dados são mais importantes do que algoritmos?



Dados de treinamento não representativos



Dados de treinamento devem ser representativos para novos casos!
(ruído na amostragem)

Dados de treinamento não representativos

Viés na amostragem e viés de não-resposta.



Eleições para presidente dos EUA (1936)
Roosevelt x Landon

Dados de baixa qualidade

Mineração, higienização e padronização dos dados

Modelo	Quilometragem (km)	Ano	Marca	...	Valor (R\$)
COROLLA	1.000	2019	Toyota	...	60 000 000
Fusquinha	100 000	1984	Volkswagem	...	2 000
Onix 2017	15, 000	2017	Chevrolet	...	30 000
⋮	⋮	⋮	⋮	⋮	⋮
Duster	10 000	2218	Renault	...	45.000

Características irrelevantes


Engenharia de características ou ***feature engineering***

- Seleção, extração e criação de características

Modelo	Quilometragem (km)	Ano	Marca	...	Valor (R\$)
Corolla	1 000	2019	Toyota	...	60 000
Fusca	100 000	1984	Volkswagem	...	2 000
Onix	15 000	2017	Chevrolet	...	30 000
⋮	⋮	⋮	⋮	⋮	⋮
Duster	10 000	2018	Renault	...	45 000


Resumindo...

DATA




+

MODEL



=

RESULT




Garbage in, garbage out!


Sobreajuste dos dados de treinamento

Sobreajuste ou *Overfitting*

- O modelo de aprendizado tem um bom desempenho **apenas no conjunto de treinamento**
- Pode acontecer quando o modelo é muito **complexo** em relação ao conjunto de treinamento



Sobreajuste dos dados de treinamento




Overfitting do conjunto de treinamento!

Sobreajuste dos dados de treinamento

Regularização

- Imposição de restrições, controladas pelos hiperparâmetros, ao Algoritmo de Aprendizagem para tornar o modelo mais simples.



A Regularização reduz os riscos de sobreajustes!

Sobreajuste dos dados de treinamento


Como resolver o sobreajuste (*overfitting*) ?

1. Utilizar um modelo mais simples;
2. Reduzir o número de atributos;
3. Restringir o modelo;
4. Adquirir mais dados;
5. Reduzir o ruído do conjunto de treinamento.

Subajuste dos dados de treinamento

Subajuste ou *Underfitting*

- O modelo de aprendizado **não** tem um bom desempenho nem mesmo no conjunto de treinamento
- Pode acontecer quando o modelo é muito **simples** em relação ao conjunto de treinamento



Subajuste dos dados de treinamento

Como resolver o subajuste (*underfitting*) ?

1. Utilizar um modelo mais complexo (“poderoso”);
2. Escolher atributos melhores;
3. Reduzir o número de restrições.

Fim