

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza




Unifor

Aprendizado Supervisionado

Os dados são rotulados, isto é, a “Resposta certa” é dada


Regressão

Prever uma saída contínua (preço)



Classificação

Prever uma saída discreta (e-mail / Spam)



Classificação

Questão	Resposta “y”	
Este email é spam?	Não	Sim
Esta transação é fraudulenta?	Não	Sim
Este tumor é maligno?	Não	Sim
	false 0	true 1


y só pode ser um dos dois valores

Classificação binária
classe = categoria


classe negativa
≠ “ruim”
indica **ausência**

classe positiva
≠ “bom”
indica **presença**

Regressão Logística




O resultado deve ser entre 0 e 1, os quais representam as classes (saída discreta)



Função **sigmóide**
Função **logística**

$$g(z) = \frac{1}{1+e^{-z}} \quad 0 < g(z) < 1$$

Regressão Logística



Função **sigmóide**
Função **logística**

Regressão linear

$$f_{\vec{w},b}(\vec{x})$$

$$z = \vec{w} \cdot \vec{x} + b$$

$$g(z) = \frac{1}{1+e^{-z}} \quad 0 < g(z) < 1$$

$$f_{\vec{w},b}(\vec{x}) = g(\vec{w} \cdot \vec{x} + b) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$

Regressão “logística”

Regressão Logística

- Probabilidade que a classe é 1
- Probabilidade que y é 1, dado a entrada x e os parâmetros w e b

$$f_{\vec{w},b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$

$$f_{\vec{w},b}(\vec{x}) = P(y = 1 | \vec{x}; \vec{w}, b)$$

$$P(y = 0) + P(y = 1) = 1$$

Exemplo:


x representa o tamanho do tumor

y pode ser 0 ou 1 (não maligno ou maligno)

$$f_{\vec{w},b}(\vec{x}) = 0.7$$

70% de chance
que y é 1

Regressão Logística - Limite de Decisão



$$f_{\vec{w},b}(\vec{x}) = g(\vec{w} \cdot \vec{x} + b) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$

$$f_{\vec{w},b}(\vec{x}) = P(y = 1 | \vec{x}; \vec{w}, b)$$

A classe predita será 0 ou 1?


$$f_{\vec{w},b}(\vec{x}) \geq 0.5?$$

Se sim, então $\hat{y} = 1$

Se não, então $\hat{y} = 0$

Regressão Logística - Limiar de Decisão

$$f_{\vec{w},b}(\vec{x}) = g(z) = g(\underset{1}{w_1}x_1 + \underset{1}{w_2}x_2 + \underset{-3}{b})$$



Limiar ou Fronteira de Decisão


$$z = \vec{w} \cdot \vec{x} + b = 0 \quad g(0) = 0,50$$

$$z = x_1 + x_2 - 3 = 0$$
$$x_1 + x_2 = 3$$

Regressão Logística - Função de Custo

A função de custo mede quão boa é a hipótese (h)

- Quando h se aproxima de $y \rightarrow J$ tende a zero.
- Quando h se afasta de $y \rightarrow J$ tende a infinito.




Log-loss / Entropia Cruzada


$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(h_{\theta}(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

Regressão Logística - Função de Custo

A hipótese é função de x



A função de custo é função de θ



Fim