

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza



Validação Cruzada

Conjunto de Treinamento e de Teste

Área	Preço
196	800
149	660
223	738
132	464
279	1060
185	600
143	630
133	398
129	424
139	486

Treinamento → Otimização da Função de Custo e Ajuste de hiperparâmetros

Conjunto de **treinamento**
80%

$$\begin{pmatrix} x^{(1)}, y^{(1)} \\ \vdots \\ x^{(m_{\text{train}})}, y^{(m_{\text{train}})} \end{pmatrix}$$

$$m_{\text{treino}} = 8$$

Conjunto de **teste**
20%

$$\begin{pmatrix} x_{\text{test}}^{(1)}, y_{\text{test}}^{(1)} \\ \vdots \\ x_{\text{test}}^{(m_{\text{teste}})}, y_{\text{test}}^{(m_{\text{teste}})} \end{pmatrix}$$

$$m_{\text{teste}} = 2$$

Validação Cruzada

Área	Preço			K-fold Cross-Validation cv = 4		
196	800	{	Conjunto de treinamento 80%	{	$(x_{cv}^{(1)}, y_{cv}^{(1)})$	$m_{val} = 2$
149	660				$\vdots$	
223	738				$(x_{cv}^{(m_{cv})}, y_{cv}^{(m_{cv})})$	
132	464					
279	1060				$(x^{(1)}, y^{(1)})$	$m_{treino} = 6$
185	600	$\vdots$				
143	630	{	Conjunto de teste 20%	{	$(x^{(m_{train})}, y^{(m_{train})})$	
133	398					
129	424				$(x_{test}^{(1)}, y_{test}^{(1)})$	$m_{teste} = 2$
139	486				$\vdots$	
						$(x_{test}^{(m_{test})}, y_{test}^{(m_{test})})$


Validação Cruzada

O conjunto de treinamento é dividido em ***k*** conjuntos menores


Para cada ***k fold***:

1. Um modelo é treinado usando uma dos ***folds*** como dados de treinamento;
2. O modelo resultante é validado na parte restante dos dados (ou seja, é usado como um conjunto de teste para calcular uma medida de desempenho, como a precisão).

K-fold (cv=5)







Validação Cruzada



Validação Cruzada

Variações



Viés e Variância

Viés e Variância

Viés


- É um erro de suposições errôneas no algoritmo de aprendizado. O viés alto pode levar a perda de relações importantes entre features e targets.

Variância


- É um erro de sensibilidade a pequenas flutuações no conjunto de treinamento. Alta variância pode resultar na modelagem de ruídos aleatórios nos dados de treinamento (overfitting) e prejudicar a generalização do modelo.

Viés e Variância - Regressão e Classificação





alto viés



alta variância



ideal



Métricas e Pontuação (scoring)

Métricas e Pontuação (scoring)

Métricas

- São funções específicas que medem uma característica particular do desempenho do modelo;
- São utilizadas para avaliar o quão bem o modelo está se saindo em termos de uma determinada medida, como precisão, recall, F1-score, erro médio quadrático, etc;
- São usadas principalmente para avaliar o desempenho do modelo em conjuntos de dados de teste ou validação, comparando as previsões do modelo com os rótulos reais.

Métricas e Pontuação (scoring)

Scoring

- O scoring, por outro lado, é uma estratégia geral para avaliar o desempenho do modelo, frequentemente usado em técnicas de **validação cruzada**;
- Ele especifica a métrica que será otimizada durante o treinamento do modelo;
- O scoring é usado para guiar a seleção de hiperparâmetros e ajustar o modelo de forma a maximizar ou minimizar a métrica específica escolhida.
- Por exemplo, ao usar validação cruzada com GridSearchCV do scikit-learn, o parâmetro scoring é usado para especificar qual métrica será usada para avaliar e comparar os modelos testados durante a busca em grade.

Métricas e Pontuação (scoring)


- Geralmente, os parâmetros seguem a convenção de que valores de retorno mais altos são melhores que valores de retorno mais baixos;
- Assim, as métricas que medem a distância entre o modelo e os dados retornam o valor negativo da métrica.

Por exemplo, métricas que medem a distância entre o modelo e os dados, como **`metrics.mean_squared_error`**, estão disponíveis como **`neg_mean_squared_error`** que retornam o valor negado da métrica.

Métricas - Regressão

Métrica	Descrição
'explained_variance'	Variância Explicada
'max_error'	Erro Residual Máximo
'neg_mean_absolute_error'	Negativo do Erro Absoluto Médio
'neg_mean_squared_error'	Negativo de Erro Quadrático Médio
'neg_root_mean_squared_error'	Negativo da raiz do Erro Quadrático Médio
'neg_mean_squared_log_error'	Negativo do Erro Logarítmico Quadrado Médio
'neg_median_absolute_error'	Erro Absoluto Mediano
'r2'	Coeficiente de determinação R^2

Métricas - Regressão



Métricas - Regressão - Variância Explicada

A variância explicada é uma medida da proporção da variabilidade dos dados que é explicada pelo modelo.

$$\text{explained_variance}(y, \hat{y}) = 1 - \frac{\text{Var}\{y - \hat{y}\}}{\text{Var}\{y\}}$$

$\hat{y}$ → saída de destino estimada

y → saída de destino correspondente (correta)

Var → Variância (quadrado do desvio padrão)

O melhor valor possível é **1.0**, valores menores são piores.

Métricas - Regressão - Erro Residual Máximo

O erro residual máximo é simplesmente o maior valor absoluto entre todos os resíduos (diferença entre o verdadeiro e o previsto) do modelo.

$$\text{Max Error}(y, \hat{y}) = \max(|y_i - \hat{y}_i|)$$

$\hat{y} \rightarrow$ saída de destino estimada

$y \rightarrow$ saída de destino correspondente (correta)

Em um modelo de regressão de saída única, perfeitamente ajustado, o `max_error` seria igual a 0 no conjunto de treinamento.

Métricas - Regressão - Erro Absoluto Médio (MAE)

Representa a média das diferenças absolutas entre os valores observados e os valores previstos pelo modelo.

$$\text{MAE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i|.$$

$\hat{y} \rightarrow$ saída de destino estimada
 $y \rightarrow$ saída de destino correspondente (correta)

Não penaliza erros grandes de forma mais severa do que erros menores, o que pode ser desejável em algumas situações.

Pode ser influenciado por valores extremos.

Métricas - Regressão - Erro Quadrático Médio (MSE)

Representa média dos quadrados dos erros de previsão (diferença entre o verdadeiro e o previsto)

$$\text{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2.$$

$\hat{y} \rightarrow$ saída de destino estimada

$y \rightarrow$ saída de destino correspondente (correta)

O MSE dá mais peso a erros maiores.

O MSE pode ser mais sensível a *outliers* do que o MAE.

Útil quando queremos penalizar mais fortemente previsões que se desviam muito dos valores reais.

Métricas - Regressão - raiz do Erro Quadrático Médio (RMSE)

Representa a raiz quadrada do MSE (Erro Médio Quadrático).

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y})^2}$$

$\hat{y} \rightarrow$ saída de destino estimada

$y \rightarrow$ saída de destino correspondente (correta)

Como o MSE, o RMSE também é sensível a *outliers* devido à sua formulação.

Métricas - Regressão - Erro Logarítmico Quadrado Médio

Representa o MSE (Erro Quadrático Médio) das transformações logarítmicas dos valores reais e previstos.

$$\text{MSLE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (\log_e(1 + y_i) - \log_e(1 + \hat{y}_i))^2.$$

É melhor para usar quando o alvo tem **crescimento exponencial**, como contagens populacionais, vendas médias de uma mercadoria ao longo de um período de anos....

Essa métrica dá mais importância às diferenças relativas menores entre os valores previstos e reais do que diferenças maiores

Métricas - Regressão - Erro Absoluto Mediano (MedAE)

Representa a mediana das diferenças absolutas entre os valores reais e os valores previstos pelo modelo.

$$\text{MedAE}(y, \hat{y}) = \text{median}(|y_1 - \hat{y}_1|, \dots, |y_n - \hat{y}_n|).$$

Fornece uma medida robusta da dispersão dos erros de previsão.

Ao usar a **mediana** em vez da média, o MedAE é menos sensível a *outliers* e é mais robusto a valores extremos nos dados.

É uma medida de desempenho mais estável em relação a valores discrepantes do que o MAE e o MSE.

Métricas - Regressão - Coeficiente de Determinação (R^2)

Representa a proporção da variância (de y) que foi explicada pelas variáveis independentes no modelo. Indica a porcentagem da variação na variável dependente que é explicada pelo modelo.

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

A melhor pontuação possível é **1,0** e pode ser negativa (porque o modelo pode ser arbitrariamente pior).

Um modelo constante que sempre prevê o valor esperado (médio) de y , desconsiderando os recursos de entrada, obteria um R^2 de **0,0**.

Métricas - Regressão - Variância Explicada x R^2


A variância explicada não considera se há um viés (bias) sistemático nas previsões do modelo, enquanto o R^2 avalia o quão bem o modelo se ajusta aos dados, incluindo qualquer viés sistemático presente.

Portanto, o R^2 é frequentemente considerado uma medida mais completa e informativa do desempenho do modelo em relação à variância explicada.

Métricas - Classificação

Métrica	Descrição
'precision'	Precisão
'recall'	Revocação, Recall ou Sensibilidade
'f1'	F1-score
'accuracy'	Acurácia
'roc_auc'	Área sob a Curva ROC

Métricas - Classificação - Matriz de Confusão



Métricas - Classificação - Precisão

Mede a proporção de exemplos positivos classificados corretamente como positivos em relação ao número total de exemplos classificados como positivos (verdadeiros positivos mais falsos positivos).

$$\text{Precision} = \frac{TP}{TP + FP}$$

“Qual a proporção de exemplos classificados como positivos que realmente são positivos?”

Métricas - Classificação - Revocação

Mede a proporção de exemplos positivos que foram corretamente identificados pelo modelo em relação ao número total de exemplos positivos (verdadeiros positivos mais falsos negativos).

$$\text{Recall} = \frac{TP}{TP + FN}$$

“Qual a proporção de exemplos positivos que foram corretamente identificados?”

Métricas - Classificação - Acurácia

Mede a proporção de previsões corretas feitas pelo modelo em relação ao número total de previsões.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

“Qual a proporção de exemplos que foram classificados corretamente pelo modelo?”

Métricas - Classificação - F1-score


É uma média harmônica da precisão e da revocação. Ele fornece um equilíbrio entre essas duas métricas;

O F1-score é especialmente útil quando há um desequilíbrio entre as classes no conjunto de dados.

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Como é uma média harmônica, o F1-score dá mais peso aos valores menores. Portanto, para obter um alto F1-score, tanto a precisão quanto a revocação devem ser altas.

Métricas - Classificação - Trade-off Precisão/Revocação



Por exemplo, em um problema médico de detecção de câncer, é importante maximizar a **revocação**, mesmo que isso signifique reduzir a precisão, pois é crucial identificar todos os casos positivos, mesmo que alguns casos negativos sejam classificados erroneamente como positivos.


Em outros cenários, como detecção de spam de e-mail, pode ser mais importante maximizar a precisão para evitar classificar erroneamente e-mails legítimos como spam, mesmo que isso signifique perder alguns e-mails de spam.

Métricas - Classificação - Curva ROC

A **Curva ROC** é uma representação gráfica da **taxa de verdadeiros positivos (revocação)** versus a **taxa de falsos positivos (1 - especificidade)** para diferentes limiares de classificação.



O eixo x representa a taxa de falsos positivos (FPR), enquanto o eixo y representa a taxa de verdadeiros positivos (TPR), que é sinônimo de revocação.

Cada ponto na Curva ROC representa um limiar de classificação diferente para o classificador binário.



Métricas - Classificação - Curva ROC (AUC-ROC)

A área sob a Curva ROC (AUC-ROC) é frequentemente usada como uma medida única do desempenho do classificador. **Quanto maior a AUC-ROC, melhor é o desempenho do classificador em distinguir entre as classes.**



Fim