

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza



Máquinas Vetores de Suporte (SVM)

SVM - Visão Geral

Máquinas Vetores de Suporte (*Support Vector Machines* - SVM) é um modelo de Aprendizado de Máquina versátil e fundamentado na Teoria de Vapnik-Chervonenkis.

Aplicações principais:

- Classificação (linear e não-linear)
- Regressão
- Detecção de anomalias (outliers)


Otimização Convexa: Ao contrário das redes neurais, o algoritmo não fica preso em mínimos locais, garantindo sempre a convergência para um mínimo global.

Cenário Ideal: É particularmente eficaz para separar dados de alta complexidade em conjuntos de pequeno a médio porte.

SVM - Essência Geométrica (O Hiperplano)

Em um problema de classificação binária, o objetivo do SVM é traçar uma fronteira de decisão que separe as classes. Essa fronteira é chamada de **hiperplano** (uma linha em 2D, um plano em 3D, etc.).

O diferencial do SVM é que ele não quer apenas “qualquer” linha que separe os dados. Ele busca a linha que passe exatamente no meio do “corredor” mais largo possível entre as duas classes. Esse corredor é chamado de **Margem**.



SVM - Formulação Matemática

Matematicamente, a fronteira é definida por:


$$w^T x + b = 0$$

- Onde w é o vetor de pesos (perpendicular ao hiperplano) e b é o viés.
- A largura total da margem é dada por $\frac{2}{||w||}$
- Portanto, para maximizar a margem, o algoritmo precisa minimizar $||w||^2$, sujeito à restrição de que nenhum ponto caia no lado errado da margem.


SVM - Vetores de Suporte

Ao treinar um SVM, o algoritmo descobre que a grande maioria dos dados do seu dataset é irrelevante para traçar a fronteira. Os únicos pontos que importam são aqueles que estão exatamente nas bordas da margem (ou invadindo ela).

Esses pontos críticos são os **Vetores de Suporte**. Se você apagar todo o resto do seu banco de dados e retreinar o modelo apenas com os vetores de suporte, o hiperplano resultante será exatamente o mesmo. É um modelo altamente esparsos e eficiente em termos de memória pós-treinamento.



SVM - Vetores de Suporte





SVM - Classificação

SVM - Classificação Linear (Fronteiras de Decisão)

Qual classificador possui a melhor fronteira de decisão para os dados disponíveis?


Fronteira de decisão de um classificador **SVM** e suas margens (linha pontilhada).



SVM - Classificação Linear (Margem Rígida)

Classificação de Margem Rígida

- Quando todas as instâncias devem ficar fora da margem e no lado correto;
- Só funciona se os dados forem linearmente separáveis;
- É sensível a *outliers*.





Provavelmente não está generalizando bem!

SVM - Classificação Linear (Margem Suave e Regularização)



Classificação de **Margem Suave**

- Objetiva encontrar um bom equilíbrio entre manter a margem a maior possível e limitar as *violações de margem*, ou seja, instâncias que terminam no meio da margem ou mesmo no lado errado;
- O hiperparâmetro de regularização C ajusta a fronteira de decisão do modelo e suas margens




SVM - Classificação Linear (Margem Suave e Regularização)

- C Alto (Strict): O modelo é penalizado severamente por cada erro de classificação no treino. A margem fica estreita, focando em acertar tudo. Risco alto de overfitting (decora o ruído).
- C Baixo (Relaxed): O modelo tolera erros no conjunto de treino em troca de uma margem mais larga e suave. Foca na visão geral, priorizando a generalização.




SVM - Classificação Não Linear (O Problema)

Considere um conjunto de dados com apenas uma característica x_1



Não é um dado
linearmente separável



Contudo, se adicionarmos uma 2ª
característica $x_2 = (x_1)^2$ podemos
separar o dado linearmente

SVM - Classificação Não Linear (“Kernel Trick”)

Quando as classes estão entrelaçadas em formatos não-lineares (como duas luas ou círculos concêntricos), um hiperplano reto nunca vai resolver. A solução seria projetar as variáveis (features) para dimensões superiores (ex: criar features polinomiais) onde elas se tornem linearmente separáveis.




O problema é que calcular transformações para dimensões infinitas é computacionalmente inviável. O Teorema de Mercer resolve isso com o **Kernel Trick**: o SVM não precisa calcular as coordenadas exatas na dimensão superior; ele só precisa saber o produto escalar (a distância/similaridade) entre os pontos nesse novo espaço.

SVM - Classificação Não Linear (“Kernel Trick”)

Os Kernels mais comuns (como no Scikit-Learn) são:

- **Linear:** O padrão. Rápido e excelente para textos e alta dimensionalidade.
- **Polinomial:** Projeta dados em curvas polinomiais.
- **RBF (Radial Basis Function):** O mais versátil. Ele projeta os dados em um espaço de dimensão infinita. Ele introduz o parâmetro γ (Gamma), que define o raio de influência de um único vetor de suporte. Um γ alto cria “ilhas” de decisão ao redor dos pontos (overfitting).




SVM - Classificação Não Linear (Projeção Dimensional)



SVM - Classificação Não Linear (Kernel Polinomial)

Kernel Polinomial

- Possibilita obter o mesmo resultado sem adicionar as características polinomiais na prática;
- Não ocorre uma “explosão” combinatória do número de características.



coef0 controla o quanto o modelo é influenciado pelos polinômios de alto grau vs. os polinômios de baixo grau

SVM - Classificação Não Linear (Introdução ao Kernel RBF)

Kernel RBF (*Radial Basis Function*)

- “Adiciona” características através de uma *função de similaridade*, a qual computa o quanto cada instância se assemelha a um **ponto de referência** específico;
- Assim como o kernel polinomial, o RBF atinge um resultado similar, como se tivesse adicionado muitas características de similaridade, sem, de fato, tê-las adicionado.

SVM - Classificação Não Linear (Função de Similaridade RBF)

Definição: Baseada na *Função Radial Gaussiana*, utilizada para calcular a proximidade geométrica entre instâncias.


Comportamento da Curva: Possui formato de sino, com valores variando entre:

- 0: Amostras muito distantes.
- 1: Amostras idênticas (no exato ponto de referência).

Hiperparâmetro: O valor de γ (Gamma) controla a largura da curva, definindo o raio de influência espacial de cada amostra.

SVM - Classificação Não Linear (Função de Similaridade RBF)

Aplicação (Exemplo Prático): Projeção de dados para novas dimensões calculando a distância até marcos de referência predefinidos (ex: $x_1 = -2$ e $x_2 = 1$).





SVM - Classificação Não Linear (Função de Similaridade RBF)

Função de similaridade: $K(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\gamma \cdot \|\mathbf{x}_1 - \mathbf{x}_2\|^2)$

Para um $\gamma = 0.30$ temos as novas características:





$$|-1 - (-2)| = 1 \quad x_2 = \exp(-0.3 \times 1^2) = 0.74$$

$$|-1 - 1| = 2 \quad x_3 = \exp(-0.3 \times 2^2) = 0.30$$



SVM - Classificação Não Linear (Hiperparâmetros do Kernel RBF)

SVC com kernel gaussiano RBF



Gamma controla a forma do kernel (o “espaço” onde os pontos parecem próximos ou distantes).

C controla o rigor do ajuste (o “quanto” o modelo se esforça para classificar perfeitamente).


SVM - Regressão

SVM - Regressão Linear

Para usar SVMs para regressão em vez de classificação, devemos ajustar o objetivo:


Classificação

Ajustar a maior margem possível entre duas classes enquanto limita as violações de margem.





Regressão

Ajustar o maior número possível de instâncias na margem enquanto reduz as violações de margem, ou seja, **instâncias fora da margem**.



SVM - Regressão Linear

A largura da margem é controlada pelo hiperparâmetro epsilon (ϵ)





Reduzir o ϵ aumenta o número de vetores de suporte, o que regulariza o modelo. Além disso, se você adicionar mais instâncias de treinamento dentro da margem, não afetará as previsões do modelo; assim, o modelo é considerado ϵ -insensitive.

SVM - Regressão Não Linear (Kernel Polinomial)

Para lidar com tarefas de regressão não linear, pode-se utilizar o modelo SVM kernalizado.

Regressão SVM em um conjunto de treinamento quadrático aleatório, utilizando um kernel polinomial de 2º grau:



Parâmetro de Regularização

A intensidade da regularização é inversamente proporcional a C.

SVM - Resumo de Implementação (Scikit-Learn)

Tarefa	Módulo Scikit-learn
Classificação Linear	<code>sklearn.svm.LinearSVC</code>
Classificação Não Linear	<code>sklearn.svm.SVC</code>
Regressão Linear	<code>sklearn.svm.LinearSVR</code>
Regressão Não Linear	<code>sklearn.svm.SVR</code>

SVM - Vantagens

- **Eficaz em Alta Dimensionalidade:** Funciona bem mesmo quando o número de características (features) supera o de amostras. A maximização da margem atua como regularização natural contra o overfitting.
- **Eficiência de Memória:** O modelo final é altamente esparsos. Ele descarta a maioria dos dados e utiliza apenas os “Vetores de Suporte” (pontos críticos nas bordas da margem) para tomar decisões.
- **Versatilidade Geométrica:** Permite o uso do “Kernel Trick” (Linear, Polinomial, RBF) para projetar os dados em dimensões superiores e resolver separações não-lineares complexas sem alterar o algoritmo de otimização.

SVM - Desvantagens

- **Risco de Overfitting na Escolha do Kernel:** Em datasets com muitas variáveis e poucas amostras, escolher um Kernel excessivamente complexo (como RBF com gamma alto) fará o modelo “decorar” o ruído em vez de generalizar.
- **Sem Estimativas Diretas de Probabilidade:** O SVM calcula distâncias espaciais nativamente, não percentuais. Obter probabilidades exige técnicas extras e custosas (como Escalonamento de Platt) via validação cruzada.
- **Baixa Escalabilidade:** O tempo de treinamento cresce de forma quadrática a cúbica $O(n^3)$. É excelente para milhares de linhas, mas torna-se impraticável e trava em volumes massivos (Big Data).

Fim