

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza




Unifor

Árvores de Decisão

Árvores de Decisão - Visão Geral

A Árvore de Decisão é um algoritmo de aprendizado supervisionado não-paramétrico utilizado para **classificação e regressão**.

O modelo constrói uma estrutura hierárquica (grafo direcionado acíclico) dividindo o espaço de características em regiões progressivamente menores e exclusivas por meio de regras de decisão lógicas simples.



Modelos: Paramétricos vs. Não-Paramétricos


- **Modelos Paramétricos (Rígidos):** Assumem uma fórmula matemática fixa desde o início. O número de parâmetros não muda com o tamanho dos dados. Ex: Regressão Linear ($y = ax + b$), que sempre aprenderá apenas dois parâmetros (a e b).
- **Modelos Não-Paramétricos (Flexíveis):** Não assumem uma equação prévia. A estrutura do modelo cresce e se molda à complexidade dos dados. Ex: Árvore de Decisão, cujo número de nós (parâmetros) varia livremente de acordo com a dificuldade do dataset.

Árvores de Decisão - Estrutura e Nomenclatura

Nó Raiz: O ponto de partida do grafo, contendo todo o conjunto de dados.

Nós Internos: Representam a aplicação de uma regra de decisão (ex: $x_1 \leq 2.5$), dividindo os dados em dois subconjuntos.

Nós Folha (Nós Terminais): Regiões finais que não sofrem mais divisões. Contêm o valor da predição (classe majoritária para classificação ou média dos valores para regressão).



Algoritmo de Treinamento (CART)

O algoritmo *Classification and Regression Trees* (CART) constrói a árvore utilizando uma abordagem top-down e gananciosa (*greedy*). Ele avalia todas as características e todos os pontos de corte possíveis para encontrar a divisão que produza os subconjuntos mais homogêneos (puros). A função de custo do CART minimiza a impureza ponderada dos subconjuntos esquerdo e direito:

$$J(k, t_k) = \frac{m_{\text{esq}}}{m} G_{\text{esq}} + \frac{m_{\text{dir}}}{m} G_{\text{dir}}$$

Onde k é a característica, t_k é o limiar de corte, m é o número de instâncias e G é a métrica de impureza.

Algoritmo de Treinamento (CART)

Métricas de Impureza (Classificação)

- **Índice Gini:** Mede a probabilidade de classificar incorretamente um elemento escolhido aleatoriamente. Mais rápido computacionalmente (padrão no Scikit-Learn).

$$G = 1 - \sum (p_i)^2$$

- **Entropia (Ganho de Informação):** Medida baseada na teoria da informação. Tende a produzir árvores mais balanceadas em comparação ao Gini.

$$H_i = - \sum_{k=1}^n p_{i,k} \log_2(p_{i,k})$$

Para **regressão**, a divisão minimiza a variância dos dados dentro do nó, geralmente medida pelo Erro Quadrático Médio (MSE).

Algoritmo de Treinamento (CART)

Imagine que queremos prever se um cliente vai comprar um produto (Sim/Não) baseando-se apenas em sua Idade.

- **Dados (Idades):** 20 (Não), 25 (Não), 30 (Sim), 35 (Não), 40 (Sim), 50 (Sim)
- **Total:** 6 amostras (3 Não, 3 Sim).

Passo 1: Ordenação e Escolha dos Cortes

O algoritmo CART ordena os dados do menor para o maior e testa o ponto médio entre cada valor consecutivo como um possível limite de corte (limiar de decisão).

- **Possíveis cortes:** 22.5, 27.5, 32.5, 37.5, 45.0.

Algoritmo de Treinamento (CART)

Passo 2: Cálculo da Impureza (Gini)

Para cada corte, o algoritmo divide os dados em dois nós (Esquerdo e Direito) e calcula a impureza. A fórmula do Gini é: $G = 1 - \sum (p_i)^2$

Avaliando o Corte em Idade ≤ 32.5 :

1. **Nó Esquerdo (≤ 32.5):** Contém as idades [20, 25, 30].
 - a. 2 "Não" e 1 "Sim". (Total: 3)
 - b. $G_{esq} = 1 - (2/3)^2 - (1/3)^2 = 1 - 0.44 - 0.11 = 0.44$
2. **Nó Direito (> 32.5):** Contém as idades [35, 40, 50].
 - a. 1 "Não" e 2 "Sim". (Total: 3)
 - b. $G_{dir} = 1 - (1/3)^2 - (2/3)^2 = 1 - 0.11 - 0.44 = 0.44$
3. **Gini Ponderado (Total do Corte):** $(3/6 \times 0.44) + (3/6 \times 0.44) = 0.44$

Algoritmo de Treinamento (CART)


Avaliando o Corte em Idade ≤ 27.5 :

1. **Nó Esquerdo (≤ 27.5):** Contém as idades [20, 25].
 - a. 2 "Não" e 0 "Sim". (Total: 2) → **Nó Puro!!**
 - b. $G_{esq} = 1 - (2/2)^2 - (0/2)^2 = 0$
2. **Nó Direito (> 27.5):** Contém as idades [30, 35, 40, 50].
 - a. 1 "Não" e 3 "Sim". (Total: 4)
 - b. $G_{dir} = 1 - (1/4)^2 - (3/4)^2 = 1 - 0.0625 - 0.5625 = 0.375$
3. **Gini Ponderado (Total do Corte):**
 - a. $(2/6 \times 0) + (4/6 \times 0.375) = 0.25$

Algoritmo de Treinamento (CART)

Passo 3: Decisão

Como o corte em 27.5 gerou um Gini Ponderado menor (0.25) do que o corte em 32.5 (0.44), o algoritmo escolhe 27.5 como a primeira regra da Árvore de Decisão. O processo então se repete recursivamente para os nós filhos.



[Total, Sim, Não]

Algoritmo de Treinamento (CART)

Regularização e Poda (Pruning)

Sem restrições, o algoritmo divide os dados até que cada folha contenha apenas uma amostra (impureza zero), resultando em **overfitting** severo e alta variância. O controle geométrico é feito por:

- **Restrições de Crescimento (Pré-poda):**
 - *max_depth*: Limita a profundidade máxima da árvore.
 - *min_samples_split*: Número mínimo de instâncias necessárias para permitir uma divisão.
 - *min_samples_leaf*: Número mínimo de instâncias que devem estar presentes em um nó folha.

Algoritmo de Treinamento (CART)

Regularização e Poda (Pruning)

- **Poda de Complexidade de Custo (Pós-poda):**

- Aplica um escalar α para penalizar o tamanho da árvore, minimizando a função:

$$R_{\alpha}(T) = R(T) + \alpha|T|$$

- Onde $R(T)$ é o erro total da árvore de treinamento e $|T|$ é o número de folhas. O aumento de α força a eliminação de ramificações que contribuem pouco para a redução do erro.


Árvores de Decisão - Classificação

Árvores de Decisão - Classificação

Árvore de Decisão do conjunto de dados íris com 2 features: ***petal length*** e ***petal width***.

A qual classe pertence uma flor de íris com comprimento da pétala de 2 cm?


Resposta: Setosa



A qual classe pertence uma flor de íris com comprimento e largura da pétala de 2.60 cm e 1.90 cm, respectivamente?

Resposta: Virginica

Árvores de Decisão - Classificação



Samples

Quantidade de instâncias às quais se aplica. Por exemplo, 100 instâncias de treinamento têm um *petal length* > 2.45 cm

Value

Quantidade de instâncias de cada classe às quais se aplica. Por exemplo, para um *petal width* > 1.75 cm, temos 0 *setosa*, 1 *versicolor* e 45 *virginica*.

Árvores de Decisão - Classificação


Coeficiente de Gini

Calcula a **impureza** do nó, isto é, um nó é puro ($gini = 0$) se todas as instâncias de treinamento às quais ele se aplica pertencerem à mesma classe.

$$G_i = 1 - \sum_{k=1}^n p_{i,k}^2$$

Por exemplo, o **Nó laranja** se aplica apenas às instâncias de treinamento *setosa*, então $gini = 0$.

$$G_4 = 1 - (0 / 54^2) - (49 / 54^2) - (5 / 54^2) = \mathbf{0.168}$$



Árvores de Decisão - Classificação

Coeficiente de Gini ou Entropia?


$$H_i = - \sum_{\substack{k=1 \\ p_{i,k} \neq 0}}^n p_{i,k} \cdot \ln(p_{i,k})$$

$$p_{i,k} = \frac{\text{nº de instâncias da classe } k}{\text{nº de instâncias no } i\text{-ésimo nó}}$$

$$\text{Gini} = 1 - (0 / 54^2) - (49 / 54^2) - (5 / 54^2) = \mathbf{0.168}$$

$$\text{Entropia} = - 49 / 54 \ln(49 / 54) - 5 / 54 \ln(5 / 54) = \mathbf{0.308}$$


Árvores de Decisão - Classificação



$Max_depth = 2 \rightarrow Max_depth = 3$

Árvores de Decisão - Classificação

Árvore de Decisão treinada em todas as features do íris



Árvores de Decisão - Classificação

Uma Árvore de Decisão também consegue estimar a probabilidade de uma instância pertencer a uma determinada classe (`predict_proba`).

petal length = 5
petal width = 1.5

```
In [5]: tree_clf.predict_proba([[5, 1.5]])  
  
Out[5]: array([[0.          , 0.90740741, 0.09259259]])
```

Probabilidades

setosa = 0
versicolor = 0.90
virginica = 0.09

```
In [6]: tree_clf.predict([[5, 1.5]])  
  
Out[6]: array([1])
```

Predição

versicolor [classe 1]

Árvores de Decisão - Classificação


Limitações (instabilidade)

- **Fronteiras Ortogonais:** Só consegue traçar divisões perpendiculares aos eixos. Isso gera fronteiras em formato de degraus para separar dados dispostos em diagonal.
- **Instabilidade Geométrica (Alta Variância):** Uma pequena alteração nos dados de treinamento (como uma rotação, por exemplo) pode resultar em uma estrutura de árvore completamente diferente. Este problema é mitigado pelo uso de *Ensembles* (Random Forest, XGBoost).

Árvores de Decisão - Classificação

Sensibilidade aos detalhes do conjunto de treinamento



A árvore é modificada apenas com a remoção da *iris versicolor* mais larga do conjunto de treinamento



Árvores de Decisão - Classificação



Sensibilidade à rotatividade do conjunto de treinamento

A árvore é modificada apenas com a rotação (45°) do conjunto de treinamento



Árvores de Decisão - Classificação

Podemos controlar o crescimento da árvore impondo restrições, como o uso do parâmetro *min_samples_leaf*. Ele define o número mínimo de amostras que um nó folha deve conter, evitando divisões excessivas e reduzindo o *overfitting*.




Árvores de Decisão - Regressão

Árvores de Decisão - Regressão

A predição será um valor ao invés de uma classe: O algoritmo irá tentar dividir o conjunto de treinamento de modo a **minimizar o *MSE* ao invés do *coeficiente de Gini***.



$$J(k, t_k) = \frac{m_L}{m} \cdot MSE_L + \frac{m_R}{m} \cdot MSE_R;$$

$$\begin{cases} MSE_{Nó} = \sum_{i \in Nó} (\hat{y}_{Nó} - y_i)^2 \\ \hat{y}_{Nó} = \frac{1}{m_{Nó}} \sum_{i \in Nó} y_i \end{cases}$$



Árvores de Decisão - Regressão



Árvore de regressão com diferentes profundidades:



Árvores de Decisão - Regressão

Impondo restrições na árvore

- *min_samples_leaf* = número mínimo de amostras que um nó folha deve ter.



Árvores de Decisão - Vantagens

- **Interpretabilidade:** Modelo “caixa-branca” (fácil explicar as regras lógicas para áreas de negócio).
- **Preparo Mínimo:** Não exige padronização ou escalonamento dos dados (ex: *StandardScaler*).
- **Versatilidade:** Lida naturalmente com relações não-lineares.

Árvores de Decisão - Desvantagens

- **Alto Risco de Overfitting:** Se não for limitada (podada), tende a “decorar” os dados de treino e falhar no mundo real.
- **Alta Instabilidade (Variância):** Uma pequena alteração nos dados de entrada pode gerar uma estrutura de árvore completamente diferente.
- **Fronteiras Ortogonais:** Só cria cortes em formato de “degraus”, tendo dificuldade com padrões diagonais. Esse é o motivo principal para usarmos *Ensembles*, como *Random Forest*, para corrigir essas falhas.

Fim