

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza



Aprendizado Ensemble

Aprendizado Ensemble – A Sabedoria das Multidões

O que seria um Aprendizado Ensemble?

- Suponha que você faça uma pergunta complexa para milhares de pessoas aleatórias e depois agrupe as respostas. Em muitos casos, será identificado que essa resposta agregada é melhor que a resposta de um especialista.

Isso é conhecido como *sabedoria das multidões*

Aristóteles → Francis Galton → James Surowiecki

Aprendizado Ensemble – Definições e Conceitos

Nesse contexto, ao agregar as previsões de um grupo de preditores, como classificadores ou regressores, você obterá previsões melhores do que com o melhor preditor individual.

Um grupo de preditores é chamado
de **ensemble** (agrupamento)

Logo, essa técnica se chama
aprendizado ensemble

e um algoritmo do aprendizado
ensemble é chamado de
método ensemble

Aprendizado Ensemble – Exemplo: Floresta Aleatória

Por exemplo, você pode treinar um grupo de classificadores de uma árvore de decisão, cada um em um subconjunto aleatório diferente do conjunto de treinamento;

Para realizar as previsões, você obtém as previsões de todas as **árvores individuais** e, em seguida, prediz a classe que obtém **mais votos**.

Esse método se chama **floresta aleatória**

Aprendizado Ensemble – Por que funciona?

Modelos individuais de machine learning geralmente sofrem de um de dois problemas principais:


- **Viés alto (Underfitting):** O modelo é simples demais e não consegue capturar a complexidade dos dados.
- **Variância alta (Overfitting):** O modelo é complexo demais, decora os dados de treino, mas falha ao fazer previsões em dados novos.

O aprendizado ensemble funciona porque a combinação de vários modelos ajuda a equilibrar o viés e a variância. Mesmo que alguns modelos individuais (chamados de weak learners ou aprendizes fracos) cometam erros, a probabilidade de que todos cometam o mesmo erro é baixa.

Classificadores de Votação

Aprendizado Ensemble - Classificadores de Votação


Suponha que você tenha treinado alguns classificadores, cada um com acurácia de 80%.



Aprendizado Ensemble - Classificadores de Votação

Uma forma simples de criar um **classificador melhor** é combinar as previsões de cada classificador e **escolher a classe mais votada (moda)**.

Classificador
hard voting



Aprendizado Ensemble - Classificadores de Votação

Hard Voting

Classificador 1: classe A

Classificador 2: classe A

Classificador 3: classe B

A previsão final será a classe A

X

Soft Voting

Classificador 1: classe A (0.6), classe B (0.4)

Classificador 2: classe A (0.7), classe B (0.3)

Classificador 3: classe A (0.4), classe B (0.6)

Soma das probabilidades para cada classe:


Classe A: $0.6 + 0.7 + 0.4 = 1.7$

Classe B: $0.4 + 0.3 + 0.6 = 1.3$


A previsão final será a classe A

Aprendizado Ensemble - Classificadores de Votação

Os Classificadores de Votação seguem a **Lei dos Grandes Números (LGN)**, que implica que, com mais tentativas, a média dos resultados se aproxima do valor esperado. Isso é essencial para a precisão desses classificadores, que baseiam suas decisões na votação de múltiplos classificadores. Em outras palavras, quanto mais tentativas são realizadas, mais a probabilidade da média aritmética dos resultados observados irá se aproximar da probabilidade real.



Aprendizado Ensemble - Métodos



Bagging e Pasting

Aprendizado Ensemble - Bagging e Pasting

Outra abordagem é utilizar o **mesmo algoritmo** de treinamento para cada preditor, mas treiná-los em **diferentes subconjuntos aleatórios** do conjunto de treinamento.

Quando a amostragem é feita **com reposição**, o método é chamado de **Bagging** (*Bootstrap Aggregating*)

Quando a amostragem é feita **sem reposição**, o método é chamado de **Pasting**

Aprendizado Ensemble - Bagging e Pasting

Bagging (*Bootstrap Aggregating*)

- O objetivo principal do Bagging é **reduzir a variância e evitar o overfitting**.
- **Como funciona:** Ele cria vários subconjuntos aleatórios a partir do conjunto de dados original (**com Bootstrap**). Um modelo base independente (geralmente uma Árvore de Decisão) é treinado em cada um desses subconjuntos em paralelo.
- **Exemplo Clássico:** Random Forest (Floresta Aleatória). É um conjunto de milhares de árvores de decisão onde cada uma dá seu “voto” para o resultado final.

Aprendizado Ensemble - Bagging e Pasting


O que seria uma amostragem com **reposição**?

Imagine pegar uma carta aleatoriamente de um baralho de cartas, escrevê-la e, em seguida, colocá-la de volta no baralho antes de pegar a próxima carta: **a mesma carta poderia ser selecionada várias vezes.**

Em outras palavras, tanto o **bagging** quanto o **pasting** permitem que as instâncias de treinamento sejam amostradas várias vezes entre vários preditores, mas apenas o **bagging** permite que as instâncias de treinamento sejam amostradas várias vezes para o mesmo preditor.

Aprendizado Ensemble - Bagging e Pasting

O que seria uma amostragem com **reposição**?



Aprendizado Ensemble - Bagging e Pasting

O que seria uma amostragem com **reposição**?

Training dataset

Obs	X_1	X_2	X_3	X_4	X_5	Y
1	X_{11}	X_{21}	X_{31}	X_{41}	X_{51}	0
2	X_{12}	X_{22}	X_{32}	X_{42}	X_{52}	1
3	X_{13}	X_{23}	X_{33}	X_{43}	X_{53}	0
4	X_{14}	X_{24}	X_{34}	X_{44}	X_{54}	0
5	X_{15}	X_{25}	X_{35}	X_{45}	X_{55}	1

Bootstrap


Obs	X_1	X_3	X_4	Y
1	X_{11}	X_{31}	X_{41}	0
2	X_{12}	X_{32}	X_{42}	1
5	X_{15}	X_{35}	X_{45}	1
1	X_{11}	X_{31}	X_{41}	0
5	X_{15}	X_{35}	X_{45}	1

Obs	X_2	X_3	X_4	Y
1	X_{21}	X_{31}	X_{41}	0
3	X_{23}	X_{33}	X_{43}	0
4	X_{24}	X_{34}	X_{44}	0
3	X_{23}	X_{33}	X_{43}	0
2	X_{22}	X_{32}	X_{42}	0

... ..

Obs	X_1	X_2	X_5	Y
2	X_{12}	X_{22}	X_{52}	1
3	X_{13}	X_{23}	X_{53}	0
5	X_{15}	X_{25}	X_{55}	1
5	X_{15}	X_{25}	X_{55}	1
3	X_{13}	X_{23}	X_{53}	0

Aprendizado Ensemble - Bagging e Pasting



Os preditores podem ser todos treinados em **paralelo**, via diferentes núcleos de CPU ou até mesmo diferentes servidores.


Da mesma forma, as previsões podem ser feitas em **paralelo**. Esta é uma das razões pelas quais o **bagging** e o **pasting** são métodos tão populares: **eles se escalonam muito bem**.

Aprendizado Ensemble - Bagging e Pasting


Depois que todos os preditores são treinados, o conjunto pode fazer uma previsão para uma nova instância simplesmente agregando as previsões de todos os preditores.

Cada preditor individual tem um viés mais alto do que se fosse treinado no conjunto de treinamento original, mas a **agregação reduz tanto o viés quanto a variância.**

Geralmente, o resultado é que o conjunto tem um viés semelhante, mas uma variância menor do que um único preditor treinado no conjunto de treinamento original.



Aprendizado Ensemble - Bagging e Pasting



Boosting

Aprendizado Ensemble – O Conceito de Boosting

O **Boosting** é uma técnica de ensemble projetada para converter vários **aprendizes fracos** em um único **aprendiz forte**. Seu objetivo central é a redução sistemática do viés (e da variância, em menor grau).

Diferente do Bagging, onde os modelos são criados de forma independente, o Boosting opera de forma **sequencial**: o primeiro modelo tenta prever os dados, e cada novo preditor subsequente foca especificamente em corrigir as falhas do seu predecessor.

Esse ciclo cria uma corrente de modelos onde o aprendizado é cumulativo, resultando em previsões finais altamente precisas.

Aprendizado Ensemble - Boosting: Weak Learners

O que são Stumps?


Um “modelo fraco” refere-se a preditores que têm um desempenho apenas ligeiramente melhor do que adivinhar aleatoriamente. O exemplo clássico são os Decision Stumps: árvores de decisão simples com apenas um nível de profundidade (uma única quebra).

Por que usá-los?


Modelos fracos raramente sofrem de overfitting. No Boosting, a força do modelo final não vem da complexidade de uma única árvore profunda, mas da combinação inteligente de centenas desses modelos simples.

Aprendizado Ensemble - Boosting: AdaBoost

Utiliza vários modelos fracos



O peso de alguns modelos é maior que outros




Aprendizado Ensemble - Boosting: AdaBoost

No **AdaBoost (Adaptive Boosting)**, a correção sequencial ocorre através do ajuste de pesos dos dados.

O algoritmo treina um classificador base e avalia suas previsões. Em seguida, ele aumenta o peso relativo das instâncias de treinamento que foram classificadas incorretamente.

O próximo classificador é treinado utilizando esses pesos atualizados, sendo forçado a prestar mais atenção e focar sua energia exatamente nos casos difíceis onde o modelo anterior falhou. O processo se repete sucessivamente.

Aprendizado Ensemble - Boosting: AdaBoost




Aprendizado Ensemble - Boosting: Gradient Boosting

Em vez de alterar os pesos das instâncias, o **Gradient Boosting (GBM)** foca diretamente na otimização matemática do erro.

Ele utiliza o conceito de gradiente descendente para treinar cada novo modelo de forma que ele preveja e minimize os erros residuais (a diferença entre a previsão e o valor real) deixados pelos modelos anteriores.

Essa abordagem é a base da evolução moderna do Machine Learning tabular. Algoritmos de altíssima performance e vencedores de competições do Kaggle derivam daqui, como **XGBoost, LightGBM e CatBoost**.

Aprendizado Ensemble - Boosting: Gradient Boosting



Aprendizado Ensemble - Boosting: Gradient Boosting

Após a conclusão do treinamento sequencial, o ensemble precisa fazer previsões para novos dados. Ele faz isso combinando o resultado de todos os aprendizes fracos gerados.

A previsão final não é uma média simples, mas sim uma **soma ponderada** (agregação ponderada) de todos os modelos da sequência. Isso significa que cada modelo recebe um peso de acordo com sua precisão individual:

- Os preditores que tiveram melhor desempenho recebem maior influência no "voto" final, consolidando a transformação de vários aprendizes fracos em um modelo preditivo forte e robusto.

Stacking

Aprendizado Ensemble - Stacking

O Stacking (ou *stacked generalization*) é uma abordagem mais heterogênea. Em vez de utilizar vários modelos da mesma família (como árvores de decisão), ele combina algoritmos de naturezas **completamente diferentes**.

O processo começa com o treinamento desses múltiplos preditores base (ex: SVM, Regressão Logística e KNN) diretamente no seu conjunto de dados original.


A grande diferença do Stacking é que as previsões individuais desses modelos base **não são simplesmente somadas ou votadas para gerar o resultado final**.

Aprendizado Ensemble - Stacking

O método abandona funções triviais de combinação, como a votação simples (hard voting) ou a média aritmética.

Em vez disso, ele introduz um **modelo de agregação inteligente** (frequentemente chamado de Blender ou Meta-modelo).

As previsões geradas pelos modelos da primeira camada são transformadas em **novos dados de entrada para o Blender**.




Aprendizado Ensemble - Stacking

Para que o blender seja treinado corretamente e sem decorar os dados (evitando overfitting), utiliza-se uma abordagem baseada em um **conjunto de separação (hold-out)**.

O conjunto de treinamento original é cuidadosamente dividido em dois subconjuntos distintos antes de qualquer treinamento.

O **primeiro subconjunto** é dedicado exclusivamente a treinar os preditores base, formando a primeira camada de inteligência do ensemble.

Aprendizado Ensemble - Stacking




Aprendizado Ensemble - Stacking

Após o treinamento da primeira camada, esses preditores avaliam o segundo subconjunto de dados (o hold-out).

Como os modelos nunca tiveram contato com esses dados durante o treino, garantimos a geração de previsões totalmente “limpas” e não enviesadas.

Essas previsões formam um **novo conjunto de dados**. Nele, as variáveis (features) são as opiniões dos modelos base, e essas informações serão usadas para ensinar o blender a prever os valores-alvo definitivos.

Aprendizado Ensemble - Stacking



Aprendizado Ensemble - Stacking


A arquitetura do Stacking é altamente escalável: é possível treinar **vários blenders** simultaneamente, utilizando modelos diferentes, e até empilhá-los em três ou mais camadas.

Para evitar o vazamento de dados nessa estrutura complexa, o conjunto original de treino precisa ser dividido em três ou mais partes.

O aprendizado ocorre em cascata:

- a Parte 1 treina a Camada 1;
- a Parte 2 cria a base de treino da Camada 2 (usando previsões da primeira);
- e a Parte 3 cria a base da Camada 3 (usando previsões da segunda).

Aprendizado Ensemble - Stacking



Resumo: As Famílias do Aprendizado Ensemble

Característica	Bagging & Pasting	Boosting	Stacking
Arquitetura	Homogênea (mesmo tipo de modelo base)	Homogênea (mesmo tipo de modelo base)	Heterogênea (modelos de naturezas diferentes)
Treinamento	Paralelo (Independentes)	Sequencial (um corrige o outro)	Camadas (Independentes na base, hierárquicos depois)
Objetivo Principal	Reduzir a Variância (evitar overfitting)	Reduzir o Viés (transformar fracos em fortes)	Encontrar a combinação ótima de diferentes modelos
Agregação (Decisão Final)	Votação simples ou Média	Soma Ponderada (melhores ganham mais peso)	Meta-modelo (Blender aprende a melhor combinação)
Exemplos Clássicos	Random Forest	AdaBoost, Gradient Boosting	N/A (É uma arquitetura customizada)

Fim