

# Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial  
Universidade de Fortaleza



# Florestas Aleatórias

# Florestas Aleatórias - Conceito e Definição

## **O que é?**

A Floresta Aleatória (Random Forest) é um algoritmo de aprendizado supervisionado que cria uma “floresta” de várias Árvores de Decisão independentes para resolver problemas de classificação e regressão.


## **Por que funciona?**

Baseia-se no princípio de Ensemble: ao agregar previsões de muitos modelos individuais (árvores), obtemos um modelo global muito mais robusto e com menor variância.

# Florestas Aleatórias - Bootstrap

Para cada árvore na floresta, o algoritmo seleciona uma amostra aleatória do dataset original com reposição (Bootstrap).

Aproximadamente 37% dos dados ficam de fora de cada árvore (Out-of-Bag), garantindo que cada árvore aprenda padrões ligeiramente diferentes dos demais.



# Florestas Aleatórias - Aleatoriedade de Atributos


Além de amostrar os dados, a Floresta Aleatória adiciona aleatoriedade na escolha das variáveis (features).

- Em cada nó de cada árvore, o algoritmo sorteia um subconjunto aleatório de atributos para decidir a melhor divisão.
- Isso impede que uma única variável muito dominante dite a estrutura de todas as árvores, forçando o modelo a explorar padrões variados e ocultos no conjunto de dados.

# Florestas Aleatórias - Arquitetura de Treinamento

1. **Seleção (Bootstrap):** Criação de múltiplos subconjuntos de dados através de amostragem aleatória com reposição, garantindo que cada árvore seja treinada com uma perspectiva diferente dos dados.
2. **Crescimento:** Construção de árvores profundas onde, em cada nó, sorteia-se um subconjunto aleatório de atributos para a divisão, forçando o modelo a explorar variáveis menos óbvias.
3. **Previsão:** Cada uma das árvores opera de forma independente e paralela para gerar um resultado individual.
4. **Agregação:** Consolidação do veredito final através de votação majoritária (para classificação) ou média aritmética (para regressão).

# Florestas Aleatórias - Arquitetura de Treinamento



> find the set of predictor variables that produce the strongest classification model

# Florestas Aleatórias - Arquitetura de Treinamento

Training dataset

| Obs | $X_1$    | $X_2$    | $X_3$    | $X_4$    | $X_5$    | $Y$ |
|-----|----------|----------|----------|----------|----------|-----|
| 1   | $X_{11}$ | $X_{21}$ | $X_{31}$ | $X_{41}$ | $X_{51}$ | 0   |
| 2   | $X_{12}$ | $X_{22}$ | $X_{32}$ | $X_{42}$ | $X_{52}$ | 1   |
| 3   | $X_{13}$ | $X_{23}$ | $X_{33}$ | $X_{43}$ | $X_{53}$ | 0   |
| 4   | $X_{14}$ | $X_{24}$ | $X_{34}$ | $X_{44}$ | $X_{54}$ | 0   |
| 5   | $X_{15}$ | $X_{25}$ | $X_{35}$ | $X_{45}$ | $X_{55}$ | 1   |

Bootstrap



| Obs | $X_1$    | $X_3$    | $X_4$    | $Y$ |
|-----|----------|----------|----------|-----|
| 1   | $X_{11}$ | $X_{31}$ | $X_{41}$ | 0   |
| 2   | $X_{12}$ | $X_{32}$ | $X_{42}$ | 1   |
| 5   | $X_{15}$ | $X_{35}$ | $X_{45}$ | 1   |
| 1   | $X_{11}$ | $X_{31}$ | $X_{41}$ | 0   |
| 5   | $X_{15}$ | $X_{35}$ | $X_{45}$ | 1   |

| Obs | $X_2$    | $X_3$    | $X_4$    | $Y$ |
|-----|----------|----------|----------|-----|
| 1   | $X_{21}$ | $X_{31}$ | $X_{41}$ | 0   |
| 3   | $X_{23}$ | $X_{33}$ | $X_{43}$ | 0   |
| 4   | $X_{24}$ | $X_{34}$ | $X_{44}$ | 0   |
| 3   | $X_{23}$ | $X_{33}$ | $X_{43}$ | 0   |
| 2   | $X_{22}$ | $X_{32}$ | $X_{42}$ | 0   |


...

| Obs | $X_1$    | $X_2$    | $X_5$    | $Y$ |
|-----|----------|----------|----------|-----|
| 2   | $X_{12}$ | $X_{22}$ | $X_{52}$ | 1   |
| 3   | $X_{13}$ | $X_{23}$ | $X_{53}$ | 0   |
| 5   | $X_{15}$ | $X_{25}$ | $X_{55}$ | 1   |
| 5   | $X_{15}$ | $X_{25}$ | $X_{55}$ | 1   |
| 3   | $X_{13}$ | $X_{23}$ | $X_{53}$ | 0   |

Ensemble of trees



...



Aggregation

Majority decision



# Florestas Aleatórias - Importância dos Atributos



Um diferencial técnico essencial é a medição da “**Feature Importance**” (Importância das Variáveis). O algoritmo calcula quanto cada atributo contribui para reduzir a impureza (Gini ou Entropia) em média (em todas as árvores).

Isso permite identificar quais variáveis são realmente cruciais para o problema, oferecendo uma camada de explicabilidade indispensável para a tomada de decisões estratégicas.

```
>>> from sklearn.datasets import load_iris
>>> iris = load_iris()
>>> rnd_clf = RandomForestClassifier(n_estimators=500, n_jobs=-1)
>>> rnd_clf.fit(iris["data"], iris["target"])
>>> for name, score in zip(iris["feature_names"], rnd_clf.feature_importances_):
...     print(name, score)
...
sepal length (cm) 0.112492250999
sepal width (cm) 0.0231192882825
petal length (cm) 0.441030464364
petal width (cm) 0.423357996355
```

# Florestas Aleatórias - Importância dos Atributos

A importância de cada pixel plotada a partir de um classificador de Floresta Aleatória treinado no conjunto de dados MNIST.



Very important

Not important

# Florestas Aleatórias - Extra-Trees

As **Árvores Extremamente Aleatórias (Extra-Trees)** são uma variação das Florestas Aleatórias que eleva a aleatoriedade ao selecionar limiares (thresholds) aleatórios para cada atributo, em vez de buscar cortes otimizados.

## Diferenciais Técnicos:

- **Velocidade:** Treinamento significativamente mais rápido, pois elimina a busca exaustiva pelo melhor limiar em cada nó.
- **Performance:** Reduz drasticamente a variância do modelo, trocando-a por um viés ligeiramente maior.
- **Generalização:** Excelente alternativa computacional para evitar o overfitting.

Fim