

Ciência de Dados

Prof. Túlio Ribeiro

Núcleo de Ciência de Dados e Inteligência Artificial
Universidade de Fortaleza



Unifor

Métodos Baseados em Distância

Métodos Baseados em Distância

Nos métodos baseados em distância, os dados são interpretados de forma estritamente espacial, isto é, o algoritmo os enxerga como pontos em um plano ou espaço multidimensional.

A premissa que rege toda essa família de algoritmos é que **similaridade equivale a proximidade espacial**, ou seja, se dois pontos estão perto um do outro geometricamente, eles tendem a pertencer à mesma classe ou possuir o mesmo comportamento.

O **KNN** é o representante mais elementar dessa família, baseando 100% de suas decisões no cálculo matemático de distância

“Diga-me com quem andas e te direi quem és”

KNN


KNN - Conceito

O KNN (K-Nearest Neighbors) é conhecido como um algoritmo de **Lazy Learning (Aprendizado Preguiçoso) e Não-Paramétrico**:

- **Lazy Learner**: Ele praticamente não tem fase de “treinamento”. Durante o treino, ele simplesmente “memoriza” (armazena) todo o conjunto de dados em memória. Todo o trabalho pesado de cálculo só acontece na hora da predição (quando você apresenta um dado novo).
- **Não-Paramétrico**: Ele não faz nenhuma suposição matemática prévia sobre a distribuição dos dados (ao contrário da Regressão Linear, que assume uma relação linear).

KNN


Suponha este conjunto de dados com 2 variáveis (features) e 10 categorias (classes)



KNN

Qual será a classe dessa nova instância?

Classificamos a nova instância observando os pontos rotulados mais próximos (vizinhos mais próximos)




KNN

Se $k = 1$, analisamos o vizinho mais próximo, e a instância será classificada como:

VERDE

Se $k = 11$, analisamos os 11 vizinhos mais próximos. Neste caso, a classificação ainda será:

VERDE




KNN

Se $k = 1$, analisamos o vizinho mais próximo, e a instância será classificada como:

VERDE


Se $k = 11$, analisamos os 11 vizinhos mais próximos. Neste caso, a classificação ainda será:

VERDE



KNN

Se a nova instância estiver nessa posição,
qual será a classificação?



KNN


Se $K = 11$ e a nova instância estiver entre duas (ou mais) categorias, simplesmente escolhemos a categoria que “recebe mais votos”.

7 vizinhos mais próximos são VERMELHOS.

3 vizinhos mais próximos são LARANJAS.

1 vizinho mais próximo é VERDE.

Como o VERMELHO recebeu a maioria dos votos, a atribuição final é VERMELHO.




KNN - Mecânica do Algoritmo

O funcionamento do KNN para prever um novo dado (não rotulado) segue 4 passos lógicos:

1. **Cálculo:** Ele mede a distância matemática entre o novo ponto e absolutamente todos os pontos que ele memorizou no dataset de treino.
2. **Ordenação:** Ele classifica essas distâncias em ordem crescente (do ponto mais próximo ao mais distante).
3. **Seleção:** Ele recorta os “K” primeiros pontos dessa lista ordenada. Estes são os K-vizinhos.
4. **Decisão:** Em tarefas de **classificação**, ele usa uma votação majoritária (a classe que mais aparecer entre os vizinhos vence). Em tarefas de **regressão**, ele calcula a média aritmética (ou mediana) do valor alvo desses vizinhos.

KNN - Mecânica do Algoritmo




KNN - Métricas de Distância

Cálculo de Distância Matemática:

- **Euclidiana:** Distância em linha reta (Teorema de Pitágoras no espaço n -dimensional). É a métrica padrão, ideal para dados numéricos contínuos.
- **Manhattan (City Block):** Soma das diferenças absolutas das coordenadas (como andar em quarteirões, sem diagonais). Útil para dados categóricos transformados ou alta presença de outliers.
- **Minkowski:** Generalização matemática das métricas acima, controlada pelo parâmetro p ($p=1$ equivale a Manhattan; $p=2$ equivale à Euclidiana).

KNN - Métricas de Distância



KNN - Parâmetro K

O valor de “K” é a quantidade de vizinhos que o algoritmo vai consultar. Escolher o K correto é crucial para o sucesso do modelo.

- **K muito baixo (ex: K = '1):** O algoritmo considera apenas a vizinhança imediata. Isso gera fronteiras de decisão super complexas, recortadas e sensíveis a qualquer ruído nos dados. Resulta em alto overfitting (alta variância).
- **K muito alto (ex: K=100):** O algoritmo consulta um grupo muito grande de vizinhos. Os padrões locais são esmagados pela classe que for maioria geral no dataset. As fronteiras ficam suaves demais, gerando underfitting (alto viés). O K ideal geralmente é encontrado testando-se vários valores via GridSearch e Validação Cruzada.

KNN Ponderado

Variante Importante: KNN Ponderado (Weighted KNN)

- **KNN Clássico:** Todos os K vizinhos possuem o mesmo peso na decisão, independentemente de quão perto ou longe estejam do novo ponto.
- **KNN Ponderado:** O valor do “voto” de cada vizinho é inversamente proporcional à sua distância. Ou seja, vizinhos mais próximos exercem maior influência na decisão final.
- **Vantagem:** Abordagem essencial para resolver empates e melhorar a precisão em regiões onde os dados estão distribuídos de forma irregular ou esparsa.

KNN - Densidade (Radius Neighbors)

- **Rigidez do “K”:** O KNN tradicional exige um número fixo de vizinhos. Em regiões muito esparsas (vazias) do dataset, o modelo é forçado a buscar vizinhos excessivamente distantes, que não representam mais o padrão local do dado.
- **Solução baseada em Densidade:** O modelo **Radius Neighbors Classifier** substitui o hiperparâmetro “K” por um Raio de distância limite.
- **Como Funciona:** Em vez de garantir uma quantidade fixa de vizinhos, o algoritmo avalia apenas os pontos dentro desse raio estipulado. Em clusters densos, a votação inclui muitos vizinhos; em áreas esparsas, inclui apenas os poucos que estão legitimamente próximos.

KNN - Cuidados na Modelagem

Por basear suas decisões inteiramente em cálculos matemáticos de distância, o KNN exige atenção em dois pontos do pré-processamento:

- **Escala dos Dados:** Variáveis com grandezas maiores (ex: faturamento de R\$ 10.000) anulam variáveis de grandeza menor (ex: 2 filhos) no cálculo da distância. É estritamente necessário aplicar normalização/padronização (MinMaxScaler ou StandardScaler) para igualar a influência das features.
- **A Maldição da Dimensionalidade:** Se o dataset tiver muitas variáveis (alta dimensão), o espaço se torna tão vasto que a distância geométrica entre quase todos os pontos acaba sendo semelhante, invalidando a premissa de “vizinhança”. Nesses casos, deve-se usar redução de dimensionalidade (como PCA) ou seleção de atributos antes de aplicar o KNN.

Detecção de Anomalias (Não-Supervisionado)

Embora o KNN seja tradicionalmente focado em tarefas supervisionadas (classificação e regressão), a sua arquitetura matemática **baseada em distâncias** é amplamente utilizada para a detecção não-supervisionada de anomalias ou clustering.

- **A Lógica de Isolamento:** O método consiste em medir o grau de isolamento de um dado. O algoritmo calcula a distância de uma amostra até aos seus K vizinhos mais próximos.
- **O Critério de Detecção:** Se esta distância for significativamente superior à média de distância observada no restante do dataset, o ponto é classificado como uma anomalia isolada no espaço de features.

Prós e Contras da Arquitetura KNN

Principais Vantagens:

- **Simplicidade e Interpretabilidade:** Implementação intuitiva e lógica de decisão transparente.
- **Flexibilidade (Não-paramétrico):** Não assume nenhuma forma matemática prévia para os dados, adaptando-se a fronteiras de decisão complexas e não-lineares.
- **Treinamento Instantâneo:** A inserção de novos dados na base é imediata, dispensando o custo computacional de retreinamento do modelo.

Principais Desvantagens:

- **Lentidão na Inferência:** A etapa de predição é ineficiente, pois o algoritmo é forçado a calcular as distâncias do novo dado contra toda a base histórica a cada nova consulta.
- **Alto Custo de Memória:** Por ser um Lazy Learner, o modelo não consolida regras; ele exige que o dataset inteiro permaneça carregado na memória RAM durante toda a sua operação.

Fim