

Iniciado em	segunda-feira, 9 mar. 2026, 11:28
Estado	Finalizada
Concluída em	segunda-feira, 9 mar. 2026, 12:11
Tempo empregado	43 minutos 26 segundos
Notas	4,00/10,00
Avaliar	1,60 de um máximo de 4,00(40%)

Questão 1

Incorreto

Atingiu 0,00 de 1,00

A equipe de engenharia de confiabilidade (SRE) de uma aplicação global de transportes está realizando uma auditoria na estabilidade dos seus servidores na nuvem para prever falhas e dimensionar a infraestrutura. O sistema registra milhões de eventos de telemetria diariamente.

Para construir um modelo preditivo eficiente, os engenheiros de dados isolaram três variáveis comportamentais distintas ocorridas no último trimestre: o número exato de falhas críticas que o servidor apresenta por semana; o tempo exato (em minutos) que decorre entre uma falha crítica e a falha seguinte; e o número de cópias de segurança (*backups*) diárias que foram concluídas com sucesso em um ciclo fixo de 30 dias de tentativas.

Determine as distribuições estatísticas corretas que modelam matematicamente, e pela respectiva ordem descrita, a contagem de falhas semanais, o tempo de espera entre as falhas e os sucessos do *backup* mensal.

- ☐ a. Distribuição Binomial / Distribuição Poisson / Distribuição Exponencial.
- ☐ b. Distribuição Poisson / Distribuição Exponencial / Distribuição Binomial.
- ☒ c. Distribuição Normal / Distribuição Binomial / Distribuição Poisson. ✖
- ☐ d. Distribuição Exponencial / Distribuição Normal / Distribuição Poisson.
- ☐ e. Distribuição Poisson / Distribuição Exponencial / Lei de Potência (Pareto).



Questão 2

Correto

Atingiu 1,00 de 1,00

Uma empresa de varejo busca otimizar a sua estratégia de preços em tempo real com base nos custos da cadeia de suprimentos. Os dados brutos chegam aos servidores com diversos valores omissos, particularmente na variável contínua "Custo de Transporte", que registra faturas de parceiros logísticos.

Durante a fase inicial do *pipeline*, a equipe técnica diagnostica que a variável "Custo de Transporte" exibe uma acentuada assimetria positiva (cauda longa à direita), evidenciando a ocorrência de fretes excepcionalmente caros. A equipe necessita preencher os valores em falta sem enviar a distribuição, posicionar este esforço de higienização na hierarquia da Pirâmide DIKW e gerar um relatório visual automatizado com alertas de qualidade de dados para compartilhar com os gestores.

Avalie as afirmações seguintes sobre a técnica estatística de imputação, o enquadramento conceitual e a ferramenta visual a adotar neste cenário, selecionando a opção correta.

- I. Devido à assimetria severa gerada pelos valores atípicos, a imputação pela Mediana é o método estatisticamente robusto para preencher os valores nulos, pois a média simples introduziria um forte viés de superestimativa no "Custo de Transporte".
- II. No contexto da Pirâmide DIKW, a etapa de limpeza e tratamento de valores ausentes converte os Dados (*Data*) brutos e ruidosos em Informação (*Information*) estruturada e contextualizada, essencial para a posterior extração de Conhecimento.
- III. Para a geração do relatório visual automatizado com alertas nativos de valores nulos e matrizes de correlação, a biblioteca Matplotlib é a escolha nativa e ideal, dado que processa a EDA completa de um *DataFrame* em uma única linha de código.

- ☐ a. Apenas as afirmativas II e III estão corretas.
- ☐ b. Todas as afirmativas estão corretas.
- ☒ c. Apenas as afirmativas I e II estão corretas. ✓
- ☐ d. Apenas a afirmativa II está correta.
- ☐ e. Apenas as afirmativas I e III estão corretas.

**Questão 3**

Correto

Atingiu 1,00 de 1,00

Uma seguradora tecnológica (*insurtech*) está construindo um modelo de risco preditivo para automatizar a cotação de apólices de automóveis. A variável alvo a ser prevista pelo algoritmo é o número exato de acidentes (sinistros) que um condutor registra em um intervalo fixo de 12 meses.

O conjunto de variáveis preditoras (*features*) inclui a "Idade do Condutor" e os "Anos de Habilitação". Na fase de avaliação bivariada, o cientista de dados observa que a relação entre estas duas variáveis numéricas não é uma linha reta perfeita, mas apresenta um comportamento estritamente monotônico crescente (conforme uma sobe, a outra também sobe, mas com ritmos variados). Além do tratamento do modelo, o departamento comercial exigiu que a análise das variáveis fosse incorporada em um *dashboard* em Streamlit, permitindo aos analistas fazer *zoom* e inspecionar pontos de dados específicos passando o mouse sobre os gráficos.

Identifique a distribuição estatística que descreve a natureza da variável alvo, a métrica apropriada para quantificar a relação monotônica entre as duas *features* e a biblioteca de visualização adequada para os requisitos do *dashboard*.

- ☐ a. Distribuição Binomial / Correlação de Pearson / Seaborn.
- ☐ b. Distribuição Poisson / Correlação de Pearson / Matplotlib.
- ☒ c. Distribuição Poisson / Correlação de Spearman / Plotly. ✓
- ☐ d. Distribuição Exponencial / Teste Qui-Quadrado / Matplotlib.
- ☐ e. Distribuição Normal / Correlação de Spearman / Seaborn.

Questão 4

Incorreto

Atingiu 0,00 de 1,00

Uma instituição financeira está atualizando o seu sistema analítico de detecção de fraudes em cartões de crédito. A variável alvo a ser prevista pelo modelo final é o status da transação, denominada 'Fraude' (classificada de forma estritamente binária: Sim ou Não).

Durante a Análise Exploratória de Dados (EDA), o analista identifica que as variáveis independentes numéricas 'Valor_Transação' e 'Idade_Usuario' possuem forte presença de anomalias (*outliers*) e exibem uma relação não-linear, mas monotonicamente crescente entre si. Adicionalmente, o projeto exige que se comprove estatisticamente a associação entre o 'Valor_Transação' (numérica contínua) e o alvo 'Fraude' (categórica binária), bem como a dependência entre o 'Tipo_Conta' (categórica nominal com três opções: Corrente, Poupança, Salário) e a própria 'Fraude'.

Identifique os métodos estatísticos e métricas matemáticas apropriadas para medir a relação entre as duas variáveis contínuas, avaliar a associação da variável contínua com o alvo binário e, por fim, testar a independência entre as duas variáveis categóricas, respectivamente.

- ☐ a. Correlação de Spearman / Teste T de Student / Teste Qui-Quadrado.
- ☒ b. Z-Score / Correlação de Spearman / ANOVA. ✖
- ☐ c. Correlação de Pearson / Kendall's Tau / V de Cramer.
- ☐ d. Correlação de Spearman / Teste Qui-Quadrado / Teste T de Student.
- ☐ e. Correlação de Pearson / ANOVA / Informação Mútua.

Questão 5

Incorreto

Atingiu 0,00 de 1,00

Uma equipe de ciência de dados de uma rede varejista está construindo um modelo preditivo para estimar o valor do tempo de vida do cliente (CLV). A base de dados contém as variáveis 'Nível_Fidelidade' (Bronze, Prata, Ouro), 'Cidade_Residência' e o 'Gasto_Mensal', sendo que esta última apresenta forte assimetria e valores extremos (*outliers*) gerados por um pequeno grupo de clientes corporativos.



O time precisa converter as variáveis em texto para representações matemáticas adequadas e escalonar o 'Gasto_Mensal' para alimentar uma rede neural que exige estritamente entradas numéricas no intervalo [0, 1]. No entanto, há uma preocupação em como os *outliers* extremos afetarão a compressão dos dados durante esse redimensionamento (*scaling*).

Avalie as asserções a seguir relativas aos métodos de codificação (*encoding*) e às técnicas de padronização/normalização aplicáveis a este cenário, selecionando a combinação correta.

- I.** A variável 'Nível_Fidelidade' deve utilizar o *One-Hot Encoding* por possuir uma hierarquia sequencial clara, enquanto a 'Cidade_Residência' exige o *Label Encoding* para evitar que o modelo presuma uma falsa ordem de magnitude entre as cidades.
- II.** A aplicação da técnica *MinMaxScaler* (Normalização) no 'Gasto_Mensal' forçará todos os valores para o intervalo [0, 1]. Contudo, devido aos *outliers* máximos isolados, a vasta maioria dos dados será "espremida" para muito perto de zero, comprimindo a variância útil do bloco principal.
- III.** A aplicação da técnica *StandardScaler* (Z-Score) altera a forma original da distribuição geométrica dos dados, corrigindo a assimetria do 'Gasto_Mensal' e transformando-o perfeitamente em uma curva simétrica (Distribuição Normal).

- ☐ a. Todas as afirmativas estão corretas.
- ☐ b. Apenas as afirmativas I e III estão corretas.
- ☐ c. Apenas a afirmativa II está correta.
- ☒ d. Apenas as afirmativas I e II estão corretas. ✖
- ☐ e. Apenas as afirmativas II e III estão corretas.

Questão 6

Incorreto

Atingiu 0,00 de 1,00

Numa empresa de comércio eletrônico em rápida expansão, a equipe de engenharia de dados lida diariamente com terabytes de informação. Esta informação inclui os perfis estruturados dos utilizadores e, simultaneamente, os dados de *clickstream* (rastreamento de cliques e navegação), que são altamente não estruturados e gerados em tempo real.

A equipe precisa de definir o repositório principal para armazenar toda esta volumetria de dados brutos de navegação sem necessidade de um esquema pré-definido. Posteriormente, num *pipeline* de pré-processamento para um modelo de recomendação, o cientista de dados depara-se com duas variáveis categóricas: *Pais_Origem* (ex: Portugal, Brasil, Espanha) e *Nivel_Subscricao* (ex: Básico, Premium, VIP).

Identifique a arquitetura de armazenamento mais apropriada para a ingestão dos dados de *clickstream* e as técnicas de codificação (*encoding*) estatisticamente corretas a aplicar nas variáveis *Pais_Origem* e *Nivel_Subscricao*, respetivamente.

- ☒ a. Data Lake / Label Encoding / One-Hot Encoding. ✖
- ☐ b. Data Lake / One-Hot Encoding / Label Encoding.
- ☐ c. Data Warehouse / Label Encoding / One-Hot Encoding.
- ☐ d. Data Warehouse / One-Hot Encoding / One-Hot Encoding.
- ☐ e. Base de Dados Relacional / One-Hot Encoding / Label Encoding.

Questão 7

Incorreto

Atingiu 0,00 de 1,00

Uma empresa de *streaming* de vídeo busca analisar o padrão de consumo dos seus usuários com o objetivo central de reduzir a taxa de abandono da plataforma (*churn*). A equipe de dados coletou milhões de registros diários sobre o comportamento de navegação e o tempo de visualização do catálogo.



O diretor de dados solicitou a criação de um painel interativo utilizando Streamlit para monitorar a saúde do negócio. Durante a análise exploratória (EDA), o cientista de dados notou que a distribuição da variável "Tempo de Visualização" apresenta uma fortíssima assimetria positiva, uma vez que a grande maioria dos usuários assiste a apenas alguns minutos por dia, mas uma minoria de usuários extremos realiza maratonas de várias horas consecutivas. A equipe precisa resumir estatisticamente este tempo de forma fidedigna e definir um indicador acionável que meça diretamente o objetivo central do negócio, distinguindo-o de uma mera métrica de vaidade.

Determine qual a medida de tendência central matematicamente apropriada para representar o tempo de visualização diante da distribuição descrita e identifique um KPI (*Key Performance Indicator*) correto para resolver o problema de negócio apresentado.

- ☐ a. Média / Quantidade de novos utilizadores registados na semana.
- ☐ b. Mediana / Número total de acessos diários à plataforma.
- ☐ c. Média / Tempo total acumulado de vídeos assistidos no mês.
- ☐ d. Mediana / Taxa de cancelamento de subscrições (Churn Rate).
- ☒ e. Moda / Taxa de cancelamento de subscrições (Churn Rate). ✖

Questão 8

Incorreto

Atingiu 0,00 de 1,00

Uma *startup* de tecnologia na área da saúde (*healthtech*) desenvolve uma aplicação web interativa utilizando Streamlit. O objetivo desta ferramenta é permitir que os médicos insiram dados clínicos e obtenham a probabilidade de um paciente sofrer uma complicação pós-cirúrgica grave. Os dados coletados incluem variáveis contínuas (como Índice de Massa Corporal e Pressão Arterial) e variáveis categóricas nominais (como Grupo Sanguíneo e Histórico de Doenças Familiares).

A equipe de *machine learning* escolheu utilizar uma Rede Neural Artificial para o modelo preditivo, a qual exige matematicamente que todos os dados numéricos de entrada estejam estritamente delimitados no intervalo $[0, 1]$. Antes de treinar o modelo, é também imperativo aplicar um método estatístico rigoroso para medir a força da associação entre a variável categórica "Grupo Sanguíneo" e a variável alvo categórica "Risco de Complicação" (Sim/Não).

Analise as afirmações abaixo sobre o pré-processamento exigido, a métrica de seleção de *features* e a tecnologia de *dashboard* a ser implementada, identificando as proposições corretas.

- I. A técnica *Min-Max Scaling* (Normalização) é obrigatória para processar as variáveis contínuas, garantindo a compressão dos valores para o intervalo rígido de $[0, 1]$, ainda que esta técnica seja mais sensível a *outliers* extremos do que a padronização via Z-Score.
- II. O Teste ANOVA é o procedimento estatístico adequado para quantificar a associação entre o "Grupo Sanguíneo" (categórica) e o "Risco de Complicação" (categórica binária), permitindo descartar variáveis irrelevantes.
- III. O *framework* Streamlit permite a criação ágil de *Data Apps* em Python, e a sua integração com a biblioteca Plotly é recomendada para dotar a interface médica de gráficos interativos (com *zoom* e *tooltips*), funcionalidade que bibliotecas estáticas como o Matplotlib não oferecem nativamente em um navegador web.

- ☐ a. Apenas as afirmativas II e III estão corretas.
- ☐ b. Apenas as afirmativas I e II estão corretas.
- ☒ c. Todas as afirmativas estão corretas. ✖
- ☐ d. Apenas as afirmativas I e III estão corretas.
- ☐ e. Apenas a afirmativa II está correta.



Questão 9

Correto

Atingiu 1,00 de 1,00

Uma plataforma tecnológica do setor imobiliário (*proptech*) está a expandir a sua operação para uma nova metrópole. Durante a fase de análise exploratória da nova base de dados, a equipe depara-se com a variável "Preço do Imóvel". Ao visualizar o gráfico de densidade (KDE), nota-se claramente a presença de dois picos distintos: um grande concentrado na faixa de preços populares e um menor na faixa de imóveis de altíssimo luxo, com a distribuição geral a apresentar uma forte assimetria nas caudas.

O analista júnior da equipe sugeriu calcular a média simples de toda a base para definir o "preço típico" da região e aplicar o método Z-Score (com limite de 3 desvios padrão) para remover eventuais erros de digitação e anomalias extremas. No entanto, o cientista de dados sénior interveio, alertando que a geometria da distribuição invalida essas abordagens e que seria necessário reestruturar a análise geométrica e a limpeza dos dados.

Identifique a abordagem analítica correta para extrair o valor representativo deste mercado imobiliário perante a distribuição descrita e o método estatístico mais robusto para a deteção dos *outliers*.

- ☐ a. Calcular a média simples global para representar o mercado e manter a aplicação da técnica de Z-Score limitando a 3 desvios padrão para remover as anomalias estritamente normais.
- ☐ b. Aplicar a média aparada (*Trimmed Mean*) cortando 10% de toda a base de dados para ignorar ambos os picos extremos e focar no vale central, utilizando o método IQR de seguida.
- ☒ c. Criar uma variável categórica para separar a base de dados em dois grupos (ex: popular e luxo) antes de extrair as métricas centrais de cada um independentemente, e utilizar o método do Intervalo Interquartil (IQR) para a deteção de *outliers*. ✓
- ☐ d. Utilizar a mediana global para encontrar o valor central seguro entre os dois picos da distribuição e aplicar o método do Intervalo Interquartil (IQR) em toda a base de dados simultaneamente.
- ☐ e. Agrupar os dados através da média ponderada populacional, uma vez que a distribuição bimodal indica uma variação no número de habitantes, e aplicar o Z-Score ajustado para 2 desvios padrão.

Questão 10

Correto

Atingiu 1,00 de 1,00



Uma equipe de ciência de dados atua em uma *proptech* (tecnologia imobiliária) que precifica imóveis em tempo real. A base de dados principal contém milhões de registros com características físicas das propriedades e histórico de transações. O modelo de regressão linear em produção começou a apresentar instabilidade nos seus coeficientes e baixa precisão na previsão de preços de imóveis de alto padrão.

Durante o diagnóstico (EDA), o engenheiro de *machine learning* identificou que a variável contínua "Área Construída (m^2)" possui uma fortíssima assimetria à direita (cauda longa). Paralelamente, notou-se uma alta dependência geométrica entre as variáveis "Área Construída (m^2)" e "Total de Cômodos", o que prejudica a interpretação matemática do modelo. Para monitorar a saúde da operação, a equipe de negócio solicitou um painel interativo (*dashboard*) que lhes permita avaliar rapidamente se o modelo está gerando lucro para a empresa.

Avalie as asserções a seguir relativas aos procedimentos analíticos e arquiteturais necessários para corrigir o modelo e entregar o painel de negócio, selecionando a combinação correta.

- I. A aplicação direta do método *StandardScaler* (Z-Score) na variável "Área Construída (m^2)" é suficiente para corrigir a sua assimetria, uma vez que transforma qualquer distribuição assimétrica em uma distribuição perfeitamente Normal.
- II. A instabilidade dos coeficientes do modelo linear é um sintoma clássico de multicolinearidade entre a "Área Construída" e o "Total de Cômodos". A remoção de uma destas variáveis redundantes é uma técnica válida para estabilizar a generalização preditiva.
- III. No desenvolvimento do *dashboard* gerencial para a equipe de negócio, a "Variação Percentual do Lucro por Transação" atua como um KPI estratégico, enquanto o "Número Total de Imóveis Processados pelo Servidor" representa apenas uma métrica operacional.

- ☐ a. Apenas a afirmativa II está correta.
- ☐ b. Apenas as afirmativas I e II estão corretas.
- ☒ c. Apenas as afirmativas II e III estão corretas. ✓
- ☐ d. Todas as afirmativas estão corretas.
- ☐ e. Apenas as afirmativas I e III estão corretas.